

Relatório Estratégico de Otimização de Custos Cloud

Análise FinOps para Redução de 15% de Gastos Mensais sem Impacto em SLA

1. Resumo Executivo

Este relatório apresenta uma análise detalhada dos custos atuais de infraestrutura em nuvem, totalizando um gasto mensal de **USD 41.800,00**. O objetivo principal é identificar e priorizar oportunidades de economia para atingir uma redução de **15% (equivalente a USD 6.270,00/mês)**, garantindo estritamente a manutenção dos Acordos de Nível de Serviço (SLAs) vigentes.

A estratégia recomendada adota a metodologia FinOps, focando inicialmente em ações de desperdício visível (Quick Wins) de baixo esforço e risco nulo, seguidas por otimizações arquiteturais controladas. As ações propostas somam uma economia potencial de **USD 7.115,00/mês (~17,02% de redução)**, superando a meta estipulada e criando uma margem de segurança operacional.

CUSTO MENSAL ATUAL	META DE REDUÇÃO (15%)	ECONOMIA MAPEADA	REDUÇÃO REAL ALCANÇADA
USD 41.800	USD 6.270	USD 7.115	17,02%


2. Panorama Atual de Gastos e Representatividade

Abaixo está detalhada a representatividade de cada serviço sobre o custo total da operação. Os recursos de **EC2 On-Demand** e **RDS PostgreSQL** representam, juntos, quase 40% de todo o faturamento cloud, tornando-se os principais alvos para análise de eficiência.

Serviço	Categoria	Custo Mensal (USD)	Representatividade (%)	Uso Médio	Observação Atual
EC2 on-demand	compute	USD 8,200	19.62%	45%	workloads variaveis
RDS PostgreSQL	databases	USD 8,200	19.62%	62%	multi-AZ
EKS	compute	USD 6,700	16.03%	58%	3 clusters
EC2 reservada	compute	USD 4,200	10.05%	72%	contrato de 1 ano
S3 Standard	storage	USD 3,100	7.42%	-	5 buckets principais
CloudWatch Logs	observability	USD 2,800	6.70%	-	retencao de 90 dias
ElastiCache Redis	databases	USD 2,100	5.02%	40%	cluster de producao
Data Transfer Out	network	USD 1,900	4.55%	-	tráfego entre regioes

Serviço	Categoria	Custo Mensal (USD)	Representatividade (%)	Uso Médio	Observação Atual
EBS gp3	storage	USD 1,600	3.83%	68%	volumes de producao
NAT Gateway	network	USD 1,200	2.87%	-	3 gateways ativos
CloudWatch Metrics	observability	USD 900	2.15%	-	
Lambda	compute	USD 900	2.15%	30%	~12M invocacoes/ mes

Distribuição de Custos Mensais por Serviço Cloud



3. Plano de Ação e Otimizações Priorizadas por Impacto

As ações foram ordenadas combinando o **impacto financeiro absoluto** e o **esforço de implementação**, priorizando iniciativas que não alteram a resiliência ou disponibilidade das aplicações produtivas.

1. Adopção de Compute Savings Plans para EC2 On-Demand

ESFORÇO: BAIXO

Impacto Financeiro: Redução estimada de 25% sobre o custo On-Demand focado em workloads estáveis remanescentes. Economia de **USD 2.050,00/mês** (Representatividade total: 19,62%).

- **Pré-requisitos:** Analisar a linha de base (baseline) de consumo de computação via AWS Cost Explorer nos últimos 30 dias para dimensionar o compromisso por hora sem risco de subutilização.
- **Riscos:** Erro no dimensionamento do valor por hora comprometido. Mitigado ao assumir um compromisso conservador de apenas 60-70% da capacidade mínima estável detectada.
- **Garantia de SLA:** Sem impacto. Trata-se de uma alteração puramente comercial/faturamento; nenhuma instância é reiniciada ou modificada.

2. Aquisição de Reserved Instances para RDS PostgreSQL

ESFORÇO: BAIXO

Impacto Financeiro: Economia de 15% através de contrato de reserva de 1 ano para banco de dados ativo. Economia de **USD 1.230,00/mês** (Representatividade total: 19,62%).

- **Pré-requisitos:** Confirmação com o time de dados de que a engine de banco de dados (PostgreSQL) e o tamanho da instância não passarão por migração estrutural drástica nos próximos 12 meses.
- **Riscos:** Falta de flexibilidade caso haja necessidade de mudar o tipo de banco de dados, porém mitigado usando instâncias modernas que permitem modificações flexíveis de tamanho dentro da mesma família.
- **Garantia de SLA:** Sem impacto. A topologia Multi-AZ (essencial para o SLA de produção) é mantida e inteiramente coberta pela reserva de instâncias equivalentes.

3. Otimização de Retenção e Filtros no CloudWatch Logs

ESFORÇO: BAIXO

Impacto Financeiro: Redução de 40% do custo com ingestão e armazenamento de logs. Redução do período de retenção padrão de 90 para 30 dias na console, exportando logs legados para S3 Glacier. Economia de **USD 1.120,00/mês**.

- **Pré-requisitos:** Configurar políticas de ciclo de vida automáticas nos Log Groups e criar rotinas de expurgo/arquivamento.
- **Riscos:** Indisponibilidade imediata de logs antigos para auditorias em tempo real. Mitigado pelo fato de os dados continuarem acessíveis de forma assíncrona no S3 Glacier.
- **Garantia de SLA:** Sem impacto. A monitoração e a resiliência dos sistemas vivos não dependem da retenção prolongada de logs em disco de alta performance.

4. Consolidação de Nós e Autoscaling Eficiente no EKS

ESFORÇO: MÉDIO

Impacto Financeiro: Redução de 15% através de consolidação de namespaces e implementação de Karpenter para substituição rápida de nós subutilizados (uso médio atual de 58%). Economia de **USD 1.005,00/mês**.

- **Pré-requisitos:** Mapeamento detalhado das requisições de CPU/Memória (Limits e Requests) dos Pods e validação de compatibilidade com Karpenter/Cluster Autoscaler.
- **Riscos:** Breve indisponibilidade local de pods durante a migração/consolidação de nós. Mitigado usando regras severas de *PodDisruptionBudgets* (PDB) e distribuindo pods entre AZs diferentes para blindar o SLA.
- **Garantia de SLA:** Mantida. O balanceamento multirregião/multi-AZ e o orçamento de indisponibilidade de pods garantem resiliência total durante as janelas de remanejamento.

5. Ativação de S3 Intelligent-Tiering nos Buckets Principais

ESFORÇO: BAIXO

Impacto Financeiro: Economia estimada de 30% no custo de storage puro ao mover automaticamente objetos não acessados para camadas frias. Economia de **USD 930,00/mês**.

- **Pré-requisitos:** Criação e validação de regras de ciclo de vida (Lifecycle Policies) nos 5 buckets principais.
- **Riscos:** Pequena taxa de monitoramento por objeto cobrada pelo Intelligent-Tiering. O risco se aplica apenas se houver milhões de arquivos extremamente pequenos (KB), o que deve ser verificado previamente.
- **Garantia de SLA:** Sem impacto. A camada de performance e latência para o S3 Intelligent-Tiering no nível frequente e infrequente permanece idêntica ao S3 Standard (milissegundos).

6. Otimizações de Rede e Cache (ElastiCache e NAT Gateway)

ESFORÇO: MÉDIO

Impacto Financeiro: Otimização de nós do Redis (uso em 40%) e implementação de VPC Endpoints (Gateway) para S3, reduzindo tráfego pago que passa desnecessariamente pelo NAT Gateway. Economia combinada de **USD 780,00/mês**.

- **Pré-requisitos:** Provisionar VPC Endpoints nas subredes privadas e alterar tabelas de roteamento internas.
- **Riscos:** Erro na configuração de tabelas de rota interromper tráfego de saída. Mitigado aplicando via Infraestrutura como Código (Terraform) em ambiente de homologação primeiro.
- **Garantia de SLA:** Sem impacto. VPC Endpoints oferecem conexões diretas e mais redundantes através do backbone interno da AWS, elevando a segurança e mantendo SLAs intactos.

4. Conclusão e Cronograma de Execução

A meta de redução de 15% (USD 6.270,00) é plenamente atingível sem penalizar a performance ou a resiliência (SLA) da infraestrutura. Recomendamos dividir a execução em duas ondas estratégicas:

- **Onda 1 (Semana 1 - FinOps Comercial):** Ativação de Savings Plans para EC2, Reserva de RDS e aplicação de políticas S3 Intelligent-Tiering + CloudWatch. **Garante imediatos USD 5.330,00/mês de economia com esforço quase nulo.**
- **Onda 2 (Semanas 2 e 3 - Otimização de Engenharia):** Implantação de Karpenter no EKS e configuração de VPC Endpoints para otimização do NAT Gateway. Garante os USD 1.785,00 remanescentes.